Cahier des Charges

Analyse de la base de connaissances PREVYO

Projet réalisé dans le cadre du **Marathon du Web**

Entreprise partenaire	EMVISTA
Solution concernée	PREVYO
Encadrant	Lucas Aubertin
Site web	https://emvista.com

Équipe MIASHS

Lounas Chikhi
Combes–Aguéra Anthony
Akkouh Ayoub
Mekki Ryan

Équipe INFOCOM

Émilie Haond
Lou Fabre
Coralie Font–Gravier
Ugo Moutin

Contents

1 Contexte **2**
- 1.1 Le Marathon du Web . . . 2
- 1.2 EMVISTA et la solution PREVYO . . . 2
- 1.3 Structure réelle des données . . . 2

2 Objectifs du projet **3**
- 2.1 Objectifs de l'équipe Data (MIASHS) . . . 3
- 2.2 Objectifs de l'équipe Communication (INFOCOM) . . . 3

3 Spécifications fonctionnelles MIASHS **5**
- 3.1 Axe 1 — Détection d'anomalies . . . 5
  - 3.1.1 Définition . . . 5
  - 3.1.2 Méthode . . . 5
  - 3.1.3 Livrable . . . 6
- 3.2 Axe 2 — Mesure de similarité et clustering . . . 7
  - 3.2.1 Les deux questions fondatrices . . . 7
  - 3.2.2 Q1 — Mesure de similarité . . . 7
  - 3.2.3 Q2 — Regroupement par clustering . . . 8
  - 3.2.4 Livrable . . . 8

4 Spécifications fonctionnelles INFOCOM **9**
- 4.1 Conception de supports print pour les salons . . . 9
- 4.2 Production d'un support vidéo . . . 9
- 4.3 Valorisation de l'offre Prevyo . . . 9
- 4.4 Création d'une communication claire et accessible . . . 10

5 Spécifications techniques INFOCOM **10**
- 5.1 Supports print (dépliant et affiche) . . . 10
- 5.2 Support vidéo . . . 10
- 5.3 Cohérence multi-supports . . . 11
- 5.4 Contraintes générales . . . 11

6 Critères de succès **12**

7 Livrables attendus **12**

1. Contexte

1.1. Le Marathon du Web

Le Marathon du Web est un hackathon collaboratif réunissant le **groupe Data MIASHS** (Master 1 Science des Données) et une équipe **COMINFO** autour d'un sujet proposé par l'entreprise partenaire EMVISTA.

1.2. EMVISTA et la solution PREVYO

EMVISTA développe des technologies NLP capables d'extraire automatiquement des **événements structurés** depuis des textes bruts (presse, rapports, mails, réseaux sociaux) et de les organiser dans une **base de connaissances sous forme de graphe**.

Chaque enregistrement de la base correspond à un événement extrait d'un contexte textuel. Il est accompagné d'un ensemble de **nœuds** (entités du graphe) et d'**arêtes** (relations entre ces entités).

1.3. Structure réelle des données

La base fournie est une collection de documents JSON. Voici un exemple représentatif de la structure d'un document :

```
{
  "_id": { "$oid": "698b35e78f03efde04a87998" },
  "type": "Thing/Abstract/Event/Win",
  "context": "Portrait des six principaux candidats qui sont en
     lice pour
               remporter le fauteuil de maire...",
  "nodes": [
    {
      "_id": "474738074",
      "form": "remporter",
      "labels": ["Thing/Abstract/Event/Win"],
      "properties": { "mood": "INF", "aspect": "STATE", "tense":
         "PRES" }
    },
    {
      "_id": "2080660730",
      "form": "fauteuil",
      "labels": ["Thing/Concrete/Inanimate"],
      "properties": { "quantity:exact": "1" }
    }
  ],
  "edges": [
    { "_id": "0", "type": "Stimulus",
      "source": "474738074", "target": "2080660730" }
  ]
}
```

> **Ce qu'il faut retenir de cette structure** :
>
> - Le champ `type` est une **taxonomie hiérarchique** (ex. `Thing/Abstract/Event/Win`)

qui décrit la catégorie de l'événement.

- Le champ `context` est le **texte source brut** depuis lequel l'événement a été extrait.
- Les `nodes` sont les entités participant à l'événement (actions, objets, temps, acteurs).
- Les `edges` sont les relations typées entre ces entités (Stimulus, Theme, Time, etc.).

2. Objectifs du projet

2.1. Objectifs de l'équipe Data (MIASHS)

Face à la liberté laissée par le sujet, l'équipe Data a choisi de se concentrer sur **deux axes précis et complémentaires**, répondant chacun à une question centrale :

Axe	Question centrale	Objectif concret
1	*"Cet événement est-il normal ?"*	Détecter les événements qui ne ressemblent à aucun autre et signaler les incohérences dans la base.
2	*"Ces deux événements se ressemblent-ils ? Si oui, comment les regrouper ?"*	Mesurer la proximité entre événements, détecter les quasi-doublons et organiser la base en clusters thématiques.

> Ces deux axes sont **complémentaires par nature** : un événement anormal est souvent un événement qui n'appartient à aucun cluster, et un quasi-doublon peut révéler une anomalie de saisie (même fait, chiffres différents). Les deux analyses se renforcent mutuellement.

2.2. Objectifs de l'équipe Communication (INFOCOM)

Mission du groupe communication :
L'objectif principal est de concevoir et produire l'ensemble des supports de communication (print et vidéo) afin de valoriser la solution Prevyo. Il s'agit de rendre son contenu accessible et compréhensible pour le grand public, et de susciter l'intérêt des visiteurs et des prospects lors des salons (ex: VivaTech) et sur le site web.

Axes de travail retenus :

- **Compréhension et vulgarisation :** Appropriation de la solution Prevyo (fonctionnement, technologie, cas d'usage) afin de vulgariser le produit technique en messages clairs, accessibles et pertinents pour les différentes cibles.

- **Conception de supports print pour les salons :** Création de dépliants et d'affiches destinés à être utilisés sur les stands afin de présenter clairement la solution Prevyo et de capter l'attention des visiteurs.

- **Production d'un support vidéo :** Réalisation d'une vidéo courte pour le site web, permettant de présenter rapidement la solution et ses bénéfices.

- **Valorisation de l'offre Prevyo :** Mise en avant des fonctionnalités clés, des cas d'usage et de la proposition de valeur à travers les différents supports de communication.

- **Création d'une communication claire et accessible :** Simplification d'un produit technique complexe pour le rendre compréhensible et attractif auprès d'un public non expert.

3. Spécifications fonctionnelles MIASHS

3.1. Axe 1 — Détection d'anomalies

3.1.1. Définition

> Une **anomalie** est un événement de la base qui se distingue significativement des autres selon une ou plusieurs dimensions mesurables, au point de suggérer soit une **erreur d'extraction**, soit une **incohérence de donnée**, soit un cas véritablement exceptionnel nécessitant une vérification humaine.

On distingue trois catégories d'anomalies adaptées à la structure des données :

Catégorie	Description
Anomalie de type	Le `type` de l'événement est rare ou incohérent avec son `context`
Anomalie structurelle	L'événement a trop peu ou trop de nœuds / arêtes par rapport à la moyenne
Anomalie sémantique	La description du `context` est sémantiquement très éloignée des autres événements du même type

3.1.2. Méthode

Représentation des événements Chaque événement e_i est représenté par un vecteur combinant :

- **Embedding du contexte textuel** : encodage du champ `context` via `sentence-transformers` (modèle multilingue).
- **Features structurelles** : nombre de nœuds, nombre d'arêtes, types de relations présents, profondeur de la taxonomie du type.
- **Encodage du type** : représentation de la hiérarchie `Thing/Abstract/Event/...` par un vecteur one-hot sur les niveaux taxonomiques.

Algorithmes utilisés Deux algorithmes non supervisés sont appliqués en parallèle

Algorithme	Ce qu'il détecte	Sortie
Isolation Forest	Anomalies globales : événements isolés dans l'espace complet des features	Score $\in [0, 1]$ par événement
DBSCAN	Anomalies locales : événements qui n'appartiennent à aucun cluster au sein de leur propre type	Label -1 (bruit) ou numéro de cluster

Explicabilité Pour chaque anomalie détectée, une explication automatique est générée, exemple :

- *"Contexte sémantiquement éloigné des autres événements de type* `Event/Win` *(similarité moyenne = 0.18)."*
- *"Structure inhabituelle : 0 arête, moyenne pour ce type = 2.8."*
- *"Type très rare dans la base : 3 occurrences sur 12 847."*

3.1.3. Livrable

Liste rangée des événements suspects avec score, niveau d'alerte et motif expliqué en langage naturel, consultable dans l'application.

3.2. Axe 2 — Mesure de similarité et clustering

3.2.1. Les deux questions fondatrices

Cet axe est structuré autour de deux questions successives :

	Question	Traduction technique
Q1	*Ces deux événements se ressemblent-ils ?*	Calculer un score de similarité $S_{ij} \in [0, 1]$ entre chaque paire
Q2	*Comment les regrouper ?*	Appliquer un algorithme de clustering sur les scores pour former des groupes cohérents

3.2.2. Q1 — Mesure de similarité

Définition

> Deux événements sont **similaires** si leur score combiné S_{ij} dépasse un seuil τ calibré empiriquement. Un score $S_{ij} > 0.90$ désigne un **quasi-doublon** potentiel.

Calcul du score Le score de similarité combine deux dimensions :

$$S_{ij} = \alpha \cdot \underbrace{\text{sim_contexte}(e_i, e_j)}_{\text{similarité textuelle}} + \beta \cdot \underbrace{\text{sim_structure}(e_i, e_j)}_{\text{similarité structurelle}}$$

avec $\alpha = 0.6$, $\beta = 0.4$ (valeurs ajustées empiriquement).

Similarité textuelle : similarité cosinus entre les embeddings des champs `context`.

Similarité structurelle : score de correspondance sur les champs du graphe :

Champ comparé	Méthode	Poids
`type` (taxonomie)	Proportion de niveaux hiérarchiques communs	0.50
Types de `nodes`	Proportion de labels communs	0.30
Types de `edges`	Proportion de relations communes	0.20

Niveaux de similarité

Score S_{ij}	Interprétation	Action proposée
> 0.90	Quasi-doublon très probable	Signaler pour vérification
$0.70 - 0.90$	Événements fortement liés	Regrouper dans le même cluster
$0.50 - 0.70$	Événements proches	Cluster secondaire
< 0.50	Événements distincts	Aucun regroupement

> **Calibration des seuils** : ces valeurs sont des points de départ. Elles seront **validées manuellement** sur un échantillon de paires du dataset réel avant d'être fixées définitivement.

Cas concret : même événement, informations différentes Un cas d'usage prioritaire est la détection de paires d'événements issus de **sources différentes** décrivant le même fait mais avec des valeurs divergentes. Ces paires ont un score S_{ij} élevé (contexte et type similaires) mais au moins un champ numérique ou temporel diffère. Exemple : même événement de type `Event/Win` avec deux candidats différents mentionnés selon la source.

3.2.3. Q2 — Regroupement par clustering

Algorithme retenu : HDBSCAN Une fois les scores calculés, les événements sont regroupés par **HDBSCAN** (Hierarchical Density-Based Spatial Clustering) :

- Pas besoin de fixer le nombre de clusters à l'avance.
- Gère nativement les événements isolés (label -1), cohérent avec l'axe anomalie.
- Adapté aux distributions irrégulières typiques des données NLP.

Pipeline :

1. Réduction des embeddings en 50 dimensions via **UMAP**.
2. Application de **HDBSCAN** (`min_cluster_size=5`).
3. Attribution d'un **label thématique automatique** à chaque cluster par TF-IDF sur les contextes (3 mots-clés représentatifs).
4. Les événements non assignés (label -1) sont transmis comme candidats anomalies à l'axe 1.

3.2.4. Livrable

Clusters thématiques labellisés, liste des quasi-doublons avec champs divergents, visualisation UMAP 2D interactive et fonction "événements similaires" dans l'application.

4. Spécifications fonctionnelles INFOCOM

4.1. Conception de supports print pour les salons

- **Dépliant :**
  - Présenter l'offre Prevyo de manière synthétique et structurée.
  - Hiérarchiser l'information (accroche, solution, bénéfices, cas d'usage).
  - Faciliter une lecture rapide en salon.
  - Améliorer l'ergonomie du support.
- **Affiche :**
  - Attirer l'attention à distance.
  - Mettre en avant un message principal impactant.
  - Assurer une lisibilité instantanée (peu de texte, éléments graphiques).
- Garantir la cohérence graphique entre les supports (charte, couleurs, typographie).

4.2. Production d'un support vidéo

- Présenter la solution Prevyo en moins d'une minute.
- Mettre en avant les bénéfices utilisateurs plutôt que les détails techniques.
- Intégrer une narration claire.
- Être adaptée à une diffusion événementielle et web (format, rythme, lisibilité sans son si nécessaire).
- Capter l'attention du public.

4.3. Valorisation de l'offre Prevyo

- Mettre en avant les fonctionnalités clés (détection, structuration, alertes, intégration).
- Illustrer les cas d'usage concrets (ex : secteur bancaire, défense, veille stratégique).
- Valoriser les éléments différenciants :
  - Technologie souveraine.
  - Déploiement flexible (SaaS / On-premise).
- Rendre visibles les bénéfices (gain de temps, prise de décision, automatisation).

4.4. Création d'une communication claire et accessible

- Simplifier les concepts techniques sans les dénaturer.
- Utiliser un vocabulaire compréhensible par un public non expert.
- Structurer les contenus pour une lecture plus rapide (titres, pictogrammes, blocs).
- Assurer une cohérence de ton et de message sur les différents supports.

5. Spécifications techniques INFOCOM

5.1. Supports print (dépliant et affiche)

- **Formats :**
  - Dépliant : A4 pour les salons plié en 3 volets et A5 en 2 volets pour le stand du marathon.
  - Affiche : A1 (adaptable selon le besoin du stand).
- **Fichiers livrés :**
  - PDF haute définition prêt à imprimer.
  - Fichiers sources (Adobe Illustrator / InDesign).
- **Contraintes techniques :**
  - Résolution : 300 dpi.
  - Mode colorimétrique : CMJN.
  - Fonds perdus avec traits de coupe : 5 mm.
  - Marges de sécurité respectées.
- **Typographie et visuels :**
  - Utilisation des polices fournies dans la charte graphique.
  - Images libres de droits ou validées par le commanditaire.
  - Respect de la charte graphique EMVISTA.

5.2. Support vidéo

- **Format :** MP4 (H.264), Résolution : Full HD (1920x1080).
- **Durée :** 45 à 60 secondes.
- **Contraintes techniques :**
  - Compatible diffusion web et écran.
  - Lecture fluide en boucle.

    - Version avec et sans sous-titres.
- **Outils de production :** Adobe After Effects / Premiere Pro / Adobe Illustrator.

5.3. Cohérence multi-supports

- Harmonisation graphique entre print et vidéo (couleurs, typographie, iconographie).
- Déclinaison cohérente des éléments visuels (logo, pictogrammes).
- Adaptation des contenus selon les formats.

5.4. Contraintes générales

- Respect des délais.
- Compatibilité avec les supports de diffusion (impression, écran, web).
- Validation préalable des contenus par le commanditaire.

6. Critères de succès

Les définitions d'anomalie et de similarité sont **formalisées et justifiées** par l'équipe.

Les seuils sont **calibrés empiriquement** sur le dataset réel, pas fixés arbitrairement.

Chaque anomalie est **explicable** en langage naturel pour un utilisateur métier.

Les quasi-doublons identifiés sont **vérifiables manuellement**.

La visualisation UMAP permet de **comprendre la structure** de la base en un coup d'œil.

Le code est **reproductible** sur le dataset fourni.

7. Livrables attendus

Priorité	Livrable	Description
Haute	Dépliant print	Support 3 volets présentant Prevyo : offre, fonctionnalités, cas d'usage, prêt à imprimer.
Haute	Affiche	Visuel impactant destiné aux salons, avec un message principal clair et lisible à distance.
Haute	Vidéo de présentation	Vidéo courte (45-60 sec) présentant la solution et ses bénéfices, prête pour une diffusion.
Moyenne	Déclinaisons graphiques	Adaptations des visuels pour différents formats.
Moyenne	Kit visuel	Éléments graphiques réutilisables (icônes, visuels, pictogrammes, styles).
Moyenne	Version digitale du dépliant	PDF pour consultation en ligne.
Basse	Recommandations créatives	Conseils sur la direction artistique et l'évolution des supports.